
Лекция 3: Динамическое программирование

Антон Романович Плаксин

Reinforcement Learning



ENVIROMENT

Цель агента - максимизировать $G = \sum_{t=0}^{T} \gamma^t R_t, \quad \gamma \in [0,1].$



Markov Decision Process

Markov Property

$$\mathbb{P}[S_{t+1}|S_t, A_t] = \mathbb{P}[S_{t+1}|S_1, A_1, S_2, A_2, \dots, S_t, A_t]$$



Markov Decision Process

Markov Property

$$\mathbb{P}[S_{t+1}|S_t, A_t] = \mathbb{P}[S_{t+1}|S_1, A_1, S_2, A_2, \dots, S_t, A_t]$$
$$\mathbb{P}[R_t|S_t, A_t] = \mathbb{P}[R_t|S_1, A_1, S_2, A_2, \dots, S_t, A_t] = 1$$

Markov Decision Process $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$

- S конечное (|S| = n) пространство состояний
- ullet $\mathcal{A}-$ конечное $(|\mathcal{A}|=m)$ пространство действий
- \mathcal{P} известная функция (тензор) вероятностей переходов между состояниями

$$\mathcal{P}(s'|s, a) = \mathbb{P}[S_{t+1} = s'|S_t = s, A_t = a]$$

• \mathcal{R} — известная функция (матрица) вознаграждений

$$\mathcal{R}(s,a) = R_t \quad \Leftrightarrow \quad \mathbb{P}[R_t|S_t = s, A_t = a] = 1$$

• $\gamma \in [0,1]$ — коэффициент дисконтирования



Policy

$$\pi(a|s) \in [0,1], \quad a \in \mathcal{A}, \quad s \in \mathcal{S}$$

- Мы задаем π
- АГЕНТ находится в начальном состоянии $S_0 \in \mathcal{S}$
- совершает действие $A_0 \sim \pi(\cdot|S_0)$
- получает награду $R_0 = \mathcal{R}(S_0, A_0)$ и переходит в следующее состояние $S_1 \sim \mathcal{P}(\cdot|S_0, A_0)$
- совершает действие $A_1 \sim \pi(\cdot|S_1)$
- получает награду $R_1 = \mathcal{R}(S_1, A_1)$ и переходит в следующее состояние $S_2 \sim \mathcal{P}(\cdot|S_1, A_1)$
- . . .
- ... $\tau = \{S_0, A_0, S_1, A_1, \dots, S_T, A_T\}, \quad G(\tau) = \sum_{t=0}^T \gamma^t \mathcal{R}(S_t, A_t)$

Наша задача

$$\mathbb{E}_{\pi}[G] \longrightarrow \max_{\pi}$$

Policy

$$\pi(a|s) \in [0,1], \quad a \in \mathcal{A}, \quad s \in \mathcal{S}$$

- Мы задаем π
- АГЕНТ находится в начальном состоянии $S_0 \in \mathcal{S}$
- совершает действие $A_0 \sim \pi(\cdot|S_0)$
- получает награду $R_0 = \mathcal{R}(S_0, A_0)$ и переходит в следующее состояние $S_1 \sim \mathcal{P}(\cdot|S_0, A_0)$
- совершает действие $A_1 \sim \pi(\cdot|S_1)$
- получает награду $R_1 = \mathcal{R}(S_1, A_1)$ и переходит в следующее состояние $S_2 \sim \mathcal{P}(\cdot|S_1, A_1)$
- •
- $\tau = \{S_0, A_0, S_1, A_1, \ldots\}, \quad G(\tau) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_t, A_t)$

Наша задача

$$\mathbb{E}_{\pi}[G] \longrightarrow \max_{\pi}$$

State-Value Function

$$\mathbb{E}_{\pi}[G] = \sum_{\tau} G(\tau) \mathbb{P}(\tau | \pi),$$

где

$$G(\tau) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_t, A_t), \qquad \mathbb{P}(\tau | \pi) = \prod_{t=0}^{\infty} \pi(A_t | S_t) \mathcal{P}(S_{t+1} | S_t, A_t)$$



State-Value Function

$$\mathbb{E}_{\pi}[G] = \sum_{\tau} G(\tau) \mathbb{P}(\tau | \pi),$$

где

$$G(\tau) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_t, A_t), \qquad \mathbb{P}(\tau | \pi) = \prod_{t=0}^{\infty} \pi(A_t | S_t) \mathcal{P}(S_{t+1} | S_t, A_t)$$

State-Value Function

$$v_{\pi}(s) = \mathbb{E}_{\pi}[G \,|\, S_0 = s]$$



State-Value Function

$$\mathbb{E}_{\pi}[G] = \sum_{\tau} G(\tau) \mathbb{P}(\tau | \pi),$$

где

$$G(\tau) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_t, A_t), \qquad \mathbb{P}(\tau | \pi) = \prod_{t=0}^{\infty} \pi(A_t | S_t) \mathcal{P}(S_{t+1} | S_t, A_t)$$

State-Value Function

$$v_{\pi}(s) = \mathbb{E}_{\pi}[G \,|\, S_0 = s]$$

Замечание

Если Policy и Environment детерминированны (не стохастические), то


$$v_{\pi}(s) = G(\tau_{\pi}),$$

где
$$\tau_{\pi} \colon \mathbb{P}(\tau_{\pi}|\pi) = 1.$$



Пример: Maze


 π



Пример: Maze

 π ⇨ ₽ 仚 ⇨ む む 仚 Start 企 ⇨ 仚 \Diamond \Diamond む \Diamond ₽ む ⇨ 仚 む **↓ ⇔** ' **⇔** Goal

$$v_{\pi}, \quad \gamma = 1$$



$$\tau = (S_0, A_0, S_1, A_1, S_2, A_2, \ldots), \quad G(\tau) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_t, A_t)$$



$$\tau = (S_0, A_0, S_1, A_1, S_2, A_2, \ldots), \quad G(\tau) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_t, A_t)$$

$$\tilde{\tau} = (S_1, A_1, S_2, A_2, S_3, A_3 \dots), \quad G(\tilde{\tau}) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_{t+1}, A_{t+1})$$

$$\tau = (S_0, A_0, S_1, A_1, S_2, A_2, \dots), \quad G(\tau) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_t, A_t)$$
$$\tilde{\tau} = (S_1, A_1, S_2, A_2, S_3, A_3 \dots), \quad G(\tilde{\tau}) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_{t+1}, A_{t+1})$$

 $G(\tau) = \mathcal{R}(S_0, A_0) + \gamma \sum_{t=1}^{\infty} \gamma^{t-1} \mathcal{R}(S_t, A_t) = \mathcal{R}(S_0, A_0) + \gamma G(\tilde{\tau})$



$$\tau = (S_0, A_0, S_1, A_1, S_2, A_2, \ldots), \quad G(\tau) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_t, A_t)$$

$$\tilde{\tau} = (S_1, A_1, S_2, A_2, S_3, A_3 \dots), \quad G(\tilde{\tau}) = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_{t+1}, A_{t+1})$$

$$G(\tau) = \mathcal{R}(S_0, A_0) + \gamma \sum_{t=1}^{\infty} \gamma^{t-1} \mathcal{R}(S_t, A_t) = \mathcal{R}(S_0, A_0) + \gamma G(\tilde{\tau})$$

$$v_{\pi}(s) = \sum_{a} \pi(a|s) \Big(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \Big)$$



$$v_{\pi}(s) = \sum_{a} \pi(a|s) \Big(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \Big)$$

$$v_{\pi}(s) = \sum_{a} \pi(a|s) \Big(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \Big)$$

$$v_{\pi}(s) = \sum_{a} \pi(a|s)\mathcal{R}(s,a) + \gamma \sum_{s'} \sum_{a} \pi(a|s)\mathcal{P}(s'|s,a)v_{\pi}(s')$$



$$v_{\pi}(s) = \sum_{a} \pi(a|s) \left(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \right)$$

$$v_{\pi}(s) = \sum_{a} \pi(a|s)\mathcal{R}(s,a) + \gamma \sum_{s'} \sum_{a} \pi(a|s)\mathcal{P}(s'|s,a)v_{\pi}(s')$$

$$\mathcal{R}_{\pi}(s) = \sum_{a} \pi(a|s)\mathcal{R}(s,a), \quad \mathcal{P}_{\pi}(s',s) = \sum_{a} \pi(a|s)\mathcal{P}(s'|s,a)$$



$$v_{\pi}(s) = \sum_{a} \pi(a|s) \left(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \right)$$

$$v_{\pi}(s) = \sum_{a} \pi(a|s)\mathcal{R}(s,a) + \gamma \sum_{s'} \sum_{a} \pi(a|s)\mathcal{P}(s'|s,a)v_{\pi}(s')$$

$$\mathcal{R}_{\pi}(s) = \sum_{a} \pi(a|s)\mathcal{R}(s,a), \quad \mathcal{P}_{\pi}(s',s) = \sum_{a} \pi(a|s)\mathcal{P}(s'|s,a)$$

$$v_{\pi}(s) = \mathcal{R}_{\pi}(s) + \gamma \sum_{s'} \mathcal{P}_{\pi}(s',s)v_{\pi}(s')$$



$$v_{\pi}(s) = \sum_{a} \pi(a|s) \left(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \right)$$

$$v_{\pi}(s) = \sum_{a} \pi(a|s) \mathcal{R}(s, a) + \gamma \sum_{s'} \sum_{a} \pi(a|s) \mathcal{P}(s'|s, a) v_{\pi}(s')$$

$$\mathcal{R}_{\pi}(s) = \sum_{a} \pi(a|s) \mathcal{R}(s, a), \quad \mathcal{P}_{\pi}(s', s) = \sum_{a} \pi(a|s) \mathcal{P}(s'|s, a)$$

$$v_{\pi}(s) = \mathcal{R}_{\pi}(s) + \gamma \sum_{s'} \mathcal{P}_{\pi}(s', s) v_{\pi}(s')$$

$$v_{\pi} = \begin{pmatrix} v_{\pi}(s_{1}) \\ \cdots \\ v_{\pi}(s_{n}) \end{pmatrix}, \mathcal{R}_{\pi} = \begin{pmatrix} \mathcal{R}_{\pi}(s_{1}) \\ \cdots \\ \mathcal{R}_{\pi}(s_{n}) \end{pmatrix}, \mathcal{P}_{\pi} = \begin{pmatrix} \mathcal{P}_{\pi}(s_{1}, s_{1}) & \cdots & \mathcal{P}_{\pi}(s_{1}, s_{n}) \\ \vdots & \ddots & \vdots \\ \mathcal{P}_{\pi}(s_{n}, s_{1}) & \cdots & \mathcal{P}_{\pi}(s_{n}, s_{n}) \end{pmatrix}$$



$$v_{\pi}(s) = \sum_{a} \pi(a|s) \Big(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \Big)$$

$$v_{\pi} = \mathcal{R}_{\pi} + \gamma \mathcal{P}_{\pi} v_{\pi}$$

$$v_{\pi}(s) = \sum_{a} \pi(a|s) \Big(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \Big)$$

$$v_{\pi} = \mathcal{R}_{\pi} + \gamma \mathcal{P}_{\pi} v_{\pi}$$

$$(E - \gamma \mathcal{P}_{\pi})v_{\pi} = \mathcal{R}_{\pi}$$



$$v_{\pi}(s) = \sum_{a} \pi(a|s) \left(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \right)$$

$$v_{\pi} = \mathcal{R}_{\pi} + \gamma \mathcal{P}_{\pi} v_{\pi}$$

$$(E - \gamma \mathcal{P}_{\pi})v_{\pi} = \mathcal{R}_{\pi}$$

$$v_{\pi} = (E - \gamma \mathcal{P}_{\pi})^{-1} \mathcal{R}_{\pi}$$

Bellman Expectation Equation для v_{π}

$$v_{\pi}(s) = \sum_{a} \pi(a|s) \left(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v_{\pi}(s') \right)$$

$$v_{\pi} = \mathcal{R}_{\pi} + \gamma \mathcal{P}_{\pi} v_{\pi}$$

$$(E - \gamma \mathcal{P}_{\pi})v_{\pi} = \mathcal{R}_{\pi}$$

$$v_{\pi} = (E - \gamma \mathcal{P}_{\pi})^{-1} \mathcal{R}_{\pi}$$

Теорема

Если $\gamma < 1$, то существует единственное v_{π} решение Bellman Expectation Equation.



Iterative Policy Evaluation

Пусть задана Policy π ; $v^0(s)$, $s \in \mathcal{S}$ — любая инициализация; K — число итераций.

Для каждого $k \in \overline{0,K}$ делаем

ullet Для каждого $s \in \mathcal{S}$ определяем

$$v^{k+1}(s) = \sum_{a} \pi(a|s) \Big(\mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a) v^k(s') \Big)$$

или сокращенно

$$v^{k+1} = \mathcal{R}_{\pi} + \gamma \mathcal{P}_{\pi} v^k$$

Теорема

Iterative Policy Evaluation сходится, то есть $v^k \to v_\pi$, $k \to \infty$. Сходимость имеет порядок $O(mn^2)$



Action-Value Function

Action-Value Function

$$q_{\pi}(s, a) = \mathbb{E}_{\pi}[G \,|\, S_0 = s, \, A_0 = a]$$

Action-Value Function

Action-Value Function

$$q_{\pi}(s, a) = \mathbb{E}_{\pi}[G \mid S_0 = s, A_0 = a]$$

Связь с v_{π}

$$v_{\pi}(s) = \sum_{a} \pi(a|s)q_{\pi}(s,a), \quad q_{\pi}(s,a) = \mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a)v_{\pi}(s')$$

Action-Value Function

Action-Value Function

$$q_{\pi}(s, a) = \mathbb{E}_{\pi}[G \mid S_0 = s, A_0 = a]$$

Связь с v_{π}

$$v_{\pi}(s) = \sum_{a} \pi(a|s)q_{\pi}(s,a), \quad q_{\pi}(s,a) = \mathcal{R}(s,a) + \gamma \sum_{s'} \mathcal{P}(s'|s,a)v_{\pi}(s')$$

$$q_{\pi}(s, a) = \mathcal{R}(s, a) + \gamma \sum_{s'} \mathcal{P}(s'|s, a) \sum_{a'} \pi(a'|s') q_{\pi}(s', a')$$



Policy Improvement

Частичный порядок для Policy

$$\pi' \ge \pi \quad \Leftrightarrow \quad v_{\pi'}(s) \ge v_{\pi}(s), \quad \forall s \in \mathcal{S}$$

Policy Improvement

Частичный порядок для Policy

$$\pi' \ge \pi \quad \Leftrightarrow \quad v_{\pi'}(s) \ge v_{\pi}(s), \quad \forall s \in \mathcal{S}$$

Greedy Policy Improvement

$$\pi'(a|s) = \begin{cases} 1, & \text{если } a \in \operatorname{argmax}_{a' \in \mathcal{A}} q_{\pi}(s, a') \\ 0, & \text{иначе} \end{cases}$$

Policy Improvement

Частичный порядок для Policy

$$\pi' \ge \pi \quad \Leftrightarrow \quad v_{\pi'}(s) \ge v_{\pi}(s), \quad \forall s \in \mathcal{S}$$

Greedy Policy Improvement

$$\pi'(a|s) = \begin{cases} 1, & \text{если } a \in \operatorname{argmax}_{a' \in \mathcal{A}} q_{\pi}(s, a') \\ 0, & \text{иначе} \end{cases}$$

Policy Improvement Theorem

Пусть задана Policy π . Если Policy π' определяется согласно Greedy Policy Improvement, то

$$\pi' \geq \pi$$



Optimal Policy

(Optimal) State-Value Function и Action-Value Function

$$v_*(s) = \max_{\pi} v_{\pi}(s), \quad q_*(s, a) = \max_{\pi} q_{\pi}(s, a)$$

Optimal Policy

(Optimal) State-Value Function и Action-Value Function

$$v_*(s) = \max_{\pi} v_{\pi}(s), \quad q_*(s, a) = \max_{\pi} q_{\pi}(s, a)$$

Optimal Policy Existence Theorem

Существует (оптимальная) Policy π_* такая, что

- $\pi_* \geq \pi, \forall \pi$
- $v_{\pi_*}(s) = v_*(s), \forall s \in \mathcal{S}$
- $q_{\pi_*}(s, a) = q_*(s, a), \forall s \in \mathcal{S}, \forall a \in \mathcal{A}$

Policy Iteration

Пусть инициализированы π^0 и заданы числа $L,K\in\mathbb{N}$. Для каждого $k\in\overline{0,K}$ делаем

• (Policy evaluation) Iterative Policy Evaluation

$$v^{l+1} = \mathcal{R}_{\pi^k} + \mathcal{P}_{\pi^k} v^l, \quad l \in \overline{0, L-1}.$$

По $v^L(s)$ построить $q^L(s, a)$.

• (Policy improvement) Greedy Policy Improvement

$$\pi^{k+1}(a|s) = \left\{ egin{array}{l} 1, \ {
m ec}$$
ли $a \in {
m argmax}_{a' \in \mathcal{A}} \, q^L(s,a') \ 0, \ {
m uhave} \end{array}
ight.$



Policy Iteration

Пусть инициализированы π^0 и заданы числа $L,K\in\mathbb{N}$. Для каждого $k\in\overline{0,K}$ делаем

• (Policy evaluation) Iterative Policy Evaluation

$$v^{l+1} = \mathcal{R}_{\pi^k} + \mathcal{P}_{\pi^k} v^l, \quad l \in \overline{0, L-1}.$$

По $v^L(s)$ построить $q^L(s,a)$.

• (Policy improvement) Greedy Policy Improvement

$$\pi^{k+1}(a|s) = \begin{cases} 1, & \text{если } a \in \operatorname{argmax}_{a' \in \mathcal{A}} q^L(s, a') \\ 0, & \text{иначе} \end{cases}$$

Теорема

Policy Iteration сходится, то есть $\pi^k \to \pi_*, k \to \infty$. Сходимость имеет порядок $O(mn^2)$



Bellman Optimality Equations для v_*

$$v_*(s) = \max_{a \in \mathcal{A}} \left(\mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s, a) v_*(s') \right)$$

Bellman Optimality Equations для v_*

$$v_*(s) = \max_{a \in \mathcal{A}} \left(\mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s, a) v_*(s') \right)$$

Bellman Optimality Equations для q_*

$$q_*(s, a) = \mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s, a) \max_{a' \in \mathcal{A}} q_*(s', a')$$

Bellman Optimality Equations для v_*

$$v_*(s) = \max_{a \in \mathcal{A}} \left(\mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s, a) v_*(s') \right)$$

Bellman Optimality Equations для q_*

$$q_*(s, a) = \mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s, a) \max_{a' \in \mathcal{A}} q_*(s', a')$$

Связь v_* и q_*

$$v_*(s) = \max_{a \in A} q_*(s,a), \quad q_*(s,a) = \mathcal{R}(s,a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s,a) v_*(s')$$



Bellman Optimality Equations для v_*

$$v_*(s) = \max_{a \in \mathcal{A}} \left(\mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s, a) v_*(s') \right)$$

Bellman Optimality Equations для q_*

$$q_*(s, a) = \mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s, a) \max_{a' \in \mathcal{A}} q_*(s', a')$$

Связь v_* и q_*

$$v_*(s) = \max_{a \in A} q_*(s, a), \quad q_*(s, a) = \mathcal{R}(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s, a) v_*(s')$$

Связь π_* и q_*

$$\pi_*(a|s) = \left\{ egin{array}{ll} 1, \ \mathrm{если} \ a \in \mathrm{argmax}_{a' \in \mathcal{A}} \ q_*(s,a') \\ 0, \ \mathrm{иначe} \end{array} \right.$$



Value Iteration

 $v^0(s),\,s\in\mathcal{S}$ — любая инициализация; K — число итераций. Для каждого $k\in\overline{0,K}$ делаем

ullet Для каждого $s\in\mathcal{S}$ определяем

$$v^{k+1}(s) = \max_{a \in \mathcal{A}} \left(\mathcal{R}(s, a) + \gamma \sum_{s'} \mathcal{P}(s'|s, a) v^k(s') \right)$$

Теорема

Value Iteration сходится, то есть $v^k \to v_*, k \to \infty$. Сходимость имеет порядок $O(mn^2)$



- Определения v_{π} , q_{π} , v_{*} , q_{*} , π_{*} будут использоваться в самом общем случае MDP (когда $\mathcal S$ и $\mathcal A$ не обязательно конечные, и $\mathcal P$ и $\mathcal R$ не обязательно известны)
- Bellman Expectation Equation для v_{π} и q_{π} , и Bellman Optimality Equation для v_{*} и q_{*} (в том виде, в котором они представлены), а также Policy Improvement Theorem и Optimal Policy Existence Theorem справедливы в случае, когда в MDP \mathcal{S} и \mathcal{A} конечны, но \mathcal{P} и \mathcal{R} не обязательно известны
- Алгоритмы Policy Iteration и Value Iteration работают в случае, когда в MDP S и A конечны, и P и R известны

Организационные вопросы

- Пятница, 17:50, аудитория 622
- Отчетность: домашние работы
- \bullet Странчика курса:
 https://github.com/imm-rl-lab/UrFU_course
- E-mail для связи:

вопросы?