

Лекция 6: Policy Gradient

Антон Романович Плаксин

Markov Decision Process

Markov Property

$$\mathbb{P}[S_{t+1}|S_t, A_t] = \mathbb{P}[S_{t+1}|S_1, A_1, S_2, A_2 \dots, S_t, A_t]$$

$$\mathbb{P}[R_t|S_t, A_t] = \mathbb{P}[R_t|S_1, A_1, S_2, A_2 \dots, S_t, A_t] = 1$$

Markov Decision Process $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$

- \mathcal{S} — бесконечное (конечное) пространство состояний
- \mathcal{A} — бесконечное (конечное) пространство действий
- \mathcal{P} — неизвестная функция вероятностей переходов между состояниями


$$\mathcal{P}(s'|s, a) = \mathbb{P}[S_{t+1} = s'|S_t = s, A_t = a]$$

- \mathcal{R} — неизвестная функция вознаграждений

$$\mathcal{R}(s, a) = R_t \quad \Leftrightarrow \quad \mathbb{P}[R_t|S_t = s, A_t = a] = 1$$

- $\gamma \in [0, 1]$ — коэффициент дисконтирования


Пример



- Состояния: \mathbb{R}^{26}
- Действия: \mathbb{R}^6
- Награда: +1 в каждый момент времени

Value-Based and Policy-Based RL

- Value-Based
 - Обучение Value Function
 - Неявные Policy
- Policy-Based
 - Без Value Function
 - Обучение Policy
- Actor-Critic
 - Обучение Value Function
 - Обучение Policy



Аппроксимация Policy

$$\pi^\eta(a|s) \approx \pi_*(a|s),$$

где $\eta \in \mathbb{R}^N$ — вектор параметров

Основная идея

Аппроксимация Policy

$$\pi^\eta(a|s) \approx \pi_*(a|s),$$

где $\eta \in \mathbb{R}^N$ — вектор параметров


Критерий качества

$$J(\eta) = \mathbb{E}_{\pi^\eta}[G_0] \rightarrow \max_{\eta},$$

где

$$G_0 = \sum_{t=0}^{\infty} \gamma^t \mathcal{R}(S_t, A_t)$$

Пример: Непрерывный Бандит



- $\mathcal{S} = \{0, 1\}$
- $\mathcal{A} = [-1, 1]$
- $\mathcal{R}(0, a) = \mathcal{R}(a)$

Пример: Непрерывный Бандит

$$\pi^\eta(a) = \pi^\eta(a|0), \quad J(\eta) = \mathbb{E}_{\pi^\eta}[G_0] = \int_{a \in \mathcal{A}} \pi^\eta(a) \mathcal{R}(a) da$$

Пример: Непрерывный Бандит

$$\pi^\eta(a) = \pi^\eta(a|0), \quad J(\eta) = \mathbb{E}_{\pi^\eta}[G_0] = \int_{a \in \mathcal{A}} \pi^\eta(a) \mathcal{R}(a) da$$

Вычисление градиента методом Monte-Carlo

$$\nabla_{\eta_i} J(\eta) \approx \frac{J(\eta + \delta e^i) - J(\eta)}{\delta}, \quad \delta > 0, \quad i \in \overline{1, N},$$

где $e_i \in \mathbb{R}^N$: $e_j^i = 1$, если $j = i$ и $e_j^i = 0$, если $j \neq i$,

$$J(\eta) \approx \frac{1}{n} \sum_{k=1}^n \mathcal{R}(a_k), \quad a_k \sim \pi^\eta(\cdot)$$

Пример: Непрерывный Бандит

$$\pi^\eta(a) = \pi^\eta(a|0), \quad J(\eta) = \mathbb{E}_{\pi^\eta}[G_0] = \int_{a \in \mathcal{A}} \pi^\eta(a) \mathcal{R}(a) da$$

Вычисление градиента с помощью Log Derivative Trick

$$\begin{aligned} \nabla_\eta J(\eta) &= \int_{a \in \mathcal{A}} \nabla_\eta \pi^\eta(a) \mathcal{R}(a) da \\ &\approx \frac{1}{n} \sum_{k=1}^n \mathcal{R}(a_k), \quad a_k \sim \nabla_\eta \pi^\eta(\cdot) \quad ? \end{aligned}$$

Пример: Непрерывный Бандит

$$\pi^\eta(a) = \pi^\eta(a|0), \quad J(\eta) = \mathbb{E}_{\pi^\eta}[G_0] = \int_{a \in \mathcal{A}} \pi^\eta(a) \mathcal{R}(a) da$$

Вычисление градиента с помощью Log Derivative Trick

$$\begin{aligned} \nabla_\eta J(\eta) &= \int_{a \in \mathcal{A}} \nabla_\eta \pi^\eta(a) \mathcal{R}(a) da = \int_{a \in \mathcal{A}} \pi^\eta(a) \frac{\nabla_\eta \pi^\eta(a)}{\pi^\eta(a)} \mathcal{R}(a) da \\ &= \int_{a \in \mathcal{A}} \pi^\eta(a) \nabla_\eta \ln \pi^\eta(a) \mathcal{R}(a) da = \mathbb{E}_{\pi^\eta}[\nabla_\eta \ln \pi^\eta(a) \mathcal{R}(a)] \\ &\approx \frac{1}{n} \sum_{k=1}^n \nabla_\eta \ln \pi^\eta(a_k) \mathcal{R}(a_k), \quad a_k \sim \pi^\eta(\cdot) \end{aligned}$$

Policy Gradient Theorem

Discounted State Distribution

$$\rho_{\pi}(s) = \sum_{t=0}^{\infty} \gamma^t \mathbb{P}[S_t = s | S_0, \pi]$$

Policy Gradient Theorem

Discounted State Distribution

$$\rho_{\pi}(s) = \sum_{t=0}^{\infty} \gamma^t \mathbb{P}[S_t = s | S_0, \pi]$$

$$\begin{aligned} \mathbb{E}_{\pi}[G_0] &= \int_{s \in \mathcal{S}} \rho_{\pi}(s) \int_{a \in \mathcal{A}} \pi(a|s) r(s, a) da ds \\ &= \mathbb{E}_{s \sim \rho_{\pi}, a \sim \pi}[r(s, a)] \end{aligned}$$

Policy Gradient Theorem

$$J(\eta) = \mathbb{E}_{\pi^\eta}[G_0] = \mathbb{E}_{s \sim \rho_{\pi^\eta}, a \sim \pi^\eta}[r(s, a)]$$

Policy Gradient Theorem

$$J(\eta) = \mathbb{E}_{\pi^\eta}[G_0] = \mathbb{E}_{s \sim \rho_{\pi^\eta}, a \sim \pi^\eta}[r(s, a)]$$

Теорема

Пусть $\pi^\eta(a|s)$ дифференцируема по η
и $\pi^\eta(a|s) \neq 0$ для любых $s \in \mathcal{S}$, $a \in \mathcal{A}$. Тогда

$$\nabla_\eta J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^\eta}, a \sim \pi^\eta}[\nabla_\eta \ln \pi^\eta(a|s) q_{\pi^\eta}(s, a)]$$

Reinforce: Основная идея

Аппроксимация Policy

$$\pi^\eta(a|s) \approx \pi_*(a|s),$$

Reinforce: Основная идея

Аппроксимация Policy

$$\pi^\eta(a|s) \approx \pi_*(a|s),$$

Policy Gradient Theorem

$$\nabla_\eta J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^\eta}, a \sim \pi^\eta} [\nabla_\eta \ln \pi^\eta(a|s) q_{\pi^\eta}(s, a)]$$

Reinforce: Основная идея

Аппроксимация Policy

$$\pi^\eta(a|s) \approx \pi_*(a|s),$$

Policy Gradient Theorem

$$\nabla_\eta J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^\eta}, a \sim \pi^\eta} [\nabla_\eta \ln \pi^\eta(a|s) q_{\pi^\eta}(s, a)]$$

Monte-Carlo Estimate

$$q_{\pi^\eta}(s, a) = \mathbb{E}_{\pi^\eta}[G_t | S_t = s, A_t = a] \approx G_t = \sum_{i=t}^{T-1} \gamma^{i-t} R_i$$

Reinforce Algorithm

Задаем структуру аппроксимации $\pi^\eta(a|s)$ и начальный вектор параметров η .

Для каждого эпизода делаем:

Reinforce Algorithm

Задаем структуру аппроксимации $\pi^\eta(a|s)$ и начальный вектор параметров η .

Для каждого эпизода делаем:

- Согласно π^η получаем траекторию $\tau = (S_0, A_0, \dots, S_T)$ и награды (R_0, \dots, R_{T-1}) . По ним определяем (G_0, \dots, G_{T-1}) :

$$G_t = \sum_{i=t}^{T-1} \gamma^{i-t} R_i$$

Reinforce Algorithm

Задаем структуру аппроксимации $\pi^\eta(a|s)$ и начальный вектор параметров η .

Для каждого эпизода делаем:

- Согласно π^η получаем траекторию $\tau = (S_0, A_0, \dots, S_T)$ и награды (R_0, \dots, R_{T-1}) . По ним определяем (G_0, \dots, G_{T-1}) :

$$G_t = \sum_{i=t}^{T-1} \gamma^{i-t} R_i$$

- Для каждого $t \in \overline{0, T-1}$ обновляем η :

$$\eta \leftarrow \eta - \alpha \nabla_\eta \ln \pi^\eta(A_t | S_t) G_t$$

On-Policy Actor-Critic: Основная идея

Аппроксимация Policy и Action-Value Function

$$\pi^\eta(a|s) \approx \pi_*(a|s), \quad Q^\theta(s, a) \approx q_{\pi^\eta}(s, a)$$

Policy Gradient Theorem

$$\nabla_\eta J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^\eta}, a \sim \pi^\eta} [\nabla_\eta \ln \pi^\eta(a|s) q_{\pi^\eta}(s, a)]$$

Аппроксимация на каждом шаге

Если $Q^\theta \approx q_{\pi^\eta}$, то

$$\begin{aligned} \nabla_\eta J(\eta) &\approx \mathbb{E}_{s \sim \rho_{\pi^\eta}, a \sim \pi^\eta} [\nabla_\eta \ln \pi^\eta(a|s) Q^\theta(s, a)] \\ &\approx \nabla_\eta \ln \pi^\eta(A_t|S_t) Q^\theta(S_t, A_t) \end{aligned}$$

On-Policy Actor-Critic: Основная идея

Аппроксимация Policy и Action-Value Function

$$\pi^\eta(a|s) \approx \pi_*(a|s), \quad Q^\theta(s, a) \approx q_{\pi^\eta}(s, a)$$

Bellman Expectation Equation для q_π

$$q_{\pi^\eta}(s, a) = \mathbb{E}_{\pi^\eta}[R_t + \gamma q_{\pi^\eta}(S_{t+1}, A_{t+1}) | S_t = s, A_t = a]$$

Аппроксимация на каждом шаге

Если

$$Q^\theta(S_t, A_t) \approx R_t + \gamma Q^\theta(S_{t+1}, A_{t+1}), \quad A_{t+1} \sim \pi^\eta(\cdot | S_t),$$

то $Q^\theta \approx q_{\pi^\eta}$

On-Policy Actor-Critic Algorithm

Задаем структуру аппроксимаций $\pi^\eta(a|s)$, $Q^\theta(s, a)$ и начальные вектора параметров η , θ .

Для каждого эпизода делаем:

Пока эпизод не закончен делаем:

- Находясь в состоянии S_t совершаем действие $A_t \sim \pi^\eta(\cdot|S_t)$, получаем награду R_t , переходим в состояние S_{t+1} .
- По (S_t, A_t, R_t, S_{t+1}) выбираем действие $A_{t+1} \sim \pi^\eta(\cdot|S_{t+1})$, определяем Loss функции:

$$Loss_1(\theta) = (R_t + \gamma Q^\theta(S_{t+1}, A_{t+1}) - Q^\theta(S_t, A_t))^2$$

$$Loss_2(\eta) = \ln \pi^\eta(A_t|S_t) Q^\theta(S_t, A_t)$$

и обновляем параметры:

$$\theta \leftarrow \theta - \alpha \nabla_\theta Loss_1(\theta), \quad \eta \leftarrow \eta + \beta \nabla_\eta Loss_2(\eta)$$

Deterministic Policy Gradient Theorem

Аппроксимация детерминированной Policy

$$\pi^\eta(s) \approx \pi_*(s)$$

Теорема

Пусть $\pi^\eta(s)$ дифференцируема по η
и $q_{\pi^\eta}(s, a)$ дифференцируема по a . Тогда

$$\nabla_\eta J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^\eta}} [\nabla_\eta q_{\pi^\eta}(s, \pi^\eta(s))]$$

DDPG (Off-Policy Actor-Critic): Основная идея

Deterministic Policy Gradient Theorem

$$\nabla_{\eta} J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^{\eta}}} [\nabla_{\eta} q_{\pi^{\eta}}(s, \pi^{\eta}(s))]$$

DDPG (Off-Policy Actor-Critic): Основная идея

Deterministic Policy Gradient Theorem

$$\nabla_{\eta} J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^{\eta}}} [\nabla_{\eta} q_{\pi^{\eta}}(s, \pi^{\eta}(s))]$$

Аппроксимация по батчу

Если $\pi \approx \pi^{\eta}$ и $Q^{\theta} \approx q_{\pi^{\eta}}$, то

$$\nabla_{\eta} J(\eta) \approx \nabla_{\eta} \left(\frac{1}{n} \sum_{i=1}^n Q^{\theta}(s_i, \pi^{\eta}(s_i)) \right)$$

DDPG (Off-Policy Actor-Critic): Основная идея

Deterministic Policy Gradient Theorem

$$\nabla_{\eta} J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^{\eta}}} [\nabla_{\eta} q_{\pi^{\eta}}(s, \pi^{\eta}(s))]$$

Аппроксимация по батчу

Если $\pi \approx \pi^{\eta}$ и $Q^{\theta} \approx q_{\pi^{\eta}}$, то

$$\nabla_{\eta} J(\eta) \approx \nabla_{\eta} \left(\frac{1}{n} \sum_{i=1}^n Q^{\theta}(s_i, \pi^{\eta}(s_i)) \right)$$

Bellman Expectation Equation для q_{π}

$$q_{\pi^{\eta}}(s, a) = \mathbb{E}[R_t + \gamma q_{\pi^{\eta}}(S_{t+1}, \pi^{\eta}(S_{t+1})) | S_t = s, A_t = a]$$

DDPG (Off-Policy Actor-Critic): Основная идея

Deterministic Policy Gradient Theorem

$$\nabla_{\eta} J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^{\eta}}} [\nabla_{\eta} q_{\pi^{\eta}}(s, \pi^{\eta}(s))]$$

Аппроксимация по батчу

Если $\pi \approx \pi^{\eta}$ и $Q^{\theta} \approx q_{\pi^{\eta}}$, то

$$\nabla_{\eta} J(\eta) \approx \nabla_{\eta} \left(\frac{1}{n} \sum_{i=1}^n Q^{\theta}(s_i, \pi^{\eta}(s_i)) \right)$$

Bellman Expectation Equation для q_{π}

$$q_{\pi^{\eta}}(s, a) = \mathbb{E}[R_t + \gamma q_{\pi^{\eta}}(S_{t+1}, \pi^{\eta}(S_{t+1})) | S_t = s, A_t = a]$$

Аппроксимация по батчу

Если

$$\frac{1}{n} \sum_{i=1}^n (r_i + \gamma Q^{\theta}(s'_i, \pi^{\eta}(s'_i)) - Q^{\theta}(s_i, a_i)) \approx 0,$$

то $Q^{\theta} \approx q_{\pi^{\eta}}$

DDPG (Off-Policy Actor-Critic) Algorithm

Задаем структуру аппроксимаций $\pi^\eta(s)$, $Q^\theta(s, a)$ и начальные вектора параметров η , θ .

Для каждого эпизода делаем:

Пока эпизод не закончен делаем:

DDPG (Off-Policy Actor-Critic) Algorithm

Задаем структуру аппроксимаций $\pi^\eta(s)$, $Q^\theta(s, a)$ и начальные вектора параметров η , θ .

Для каждого эпизода делаем:

Пока эпизод не закончен делаем:

- Находясь в состоянии S_t совершаем действие

$$A_t = \pi^\eta(S_t) + Noise,$$

получаем награду R_t переходим в состояние S_{t+1} .

Сохраняем $(S_t, A_t, R_t, S_{t+1}) \rightarrow Memory$

DDPG (Off-Policy Actor-Critic) Algorithm

Задаем структуру аппроксимаций $\pi^\eta(s)$, $Q^\theta(s, a)$ и начальные вектора параметров η , θ .

Для каждого эпизода делаем:

Пока эпизод не закончен делаем:

- Находясь в состоянии S_t совершаем действие

$$A_t = \pi^\eta(S_t) + \text{Noise},$$

получаем награду R_t переходим в состояние S_{t+1} .

Сохраняем $(S_t, A_t, R_t, S_{t+1}) \rightarrow \text{Memory}$

- Берем $\{(s_i, a_i, r_i, s'_i)\}_{i=1}^n \leftarrow \text{Memory}$, определяем значения

$$y_i = r_i + \gamma Q^\theta(s'_i, \pi^\eta(s'_i))$$

функции потерь

$$Loss_1(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - Q^\theta(s_i, a_i))^2, \quad Loss_2(\eta) = \frac{1}{n} \sum_{i=1}^n Q^\theta(s_i, \pi^\eta(s_i))$$

и обновляем вектор параметров

$$\theta \leftarrow \theta - \alpha \nabla_\theta Loss_1(\theta), \quad \eta \leftarrow \eta + \beta \nabla_\eta Loss_2(\eta), \quad \alpha, \beta > 0$$

DDPG (Off-Policy Actor-Critic) Algorithm

Задаем структуру аппроксимаций $\pi^\eta(s)$, $Q^\theta(s, a)$ и начальные вектора параметров η , θ .

Для каждого эпизода делаем:

Пока эпизод не закончен делаем:

- Находясь в состоянии S_t совершаем действие

$$A_t = \pi^\eta(S_t) + \text{Noise},$$

получаем награду R_t переходим в состояние S_{t+1} .

Сохраняем $(S_t, A_t, R_t, S_{t+1}) \rightarrow \text{Memory}$

- Берем $\{(s_i, a_i, r_i, s'_i)\}_{i=1}^n \leftarrow \text{Memory}$, определяем значения

$$y_i = r_i + \gamma Q^\theta(s'_i, \pi^\eta(s'_i))$$

функции потерь

$$\text{Loss}_1(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - Q^\theta(s_i, a_i))^2, \quad \text{Loss}_2(\eta) = \frac{1}{n} \sum_{i=1}^n Q^\theta(s_i, \pi^\eta(s_i))$$

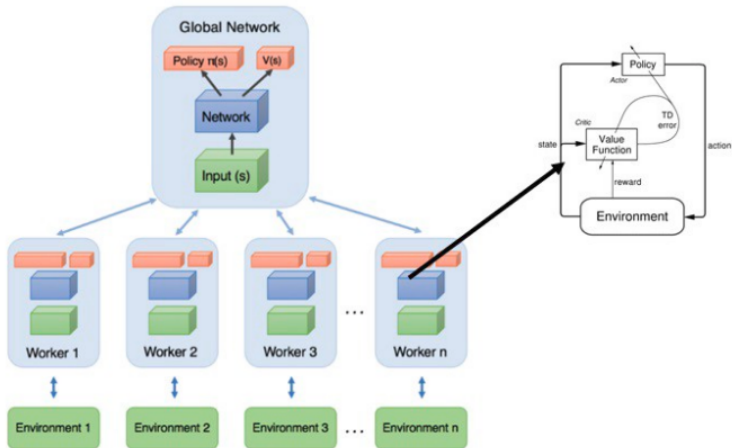
и обновляем вектор параметров

$$\theta \leftarrow \theta - \alpha \nabla_\theta \text{Loss}_1(\theta), \quad \eta \leftarrow \eta + \beta \nabla_\eta \text{Loss}_2(\eta), \quad \alpha, \beta > 0$$

- Уменьшаем *Noise*

Asynchronous Approach

Asynchronous Approach



Advantage Actor-Critic (A2C): Основная идея

Policy Gradient Theorem

$$\nabla_{\eta} J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^{\eta}}, a \sim \pi^{\eta}} [\nabla_{\eta} \ln \pi^{\eta}(a|s) (q_{\pi^{\eta}}(s, a) - b(s))]$$

Advantage Actor-Critic (A2C): Основная идея

Policy Gradient Theorem

$$\nabla_{\eta} J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^{\eta}}, a \sim \pi^{\eta}} [\nabla_{\eta} \ln \pi^{\eta}(a|s) (q_{\pi^{\eta}}(s, a) - b(s))]$$

Advantage Function

$$b(s) = v_{\pi^{\eta}}(s), \quad a_{\pi^{\eta}}(s, a) = q_{\pi^{\eta}}(s, a) - v_{\pi^{\eta}}(s)$$

Advantage Actor-Critic (A2C): Основная идея

Policy Gradient Theorem

$$\nabla_{\eta} J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^{\eta}}, a \sim \pi^{\eta}} [\nabla_{\eta} \ln \pi^{\eta}(a|s) (q_{\pi^{\eta}}(s, a) - b(s))]$$

Advantage Function

$$b(s) = v_{\pi^{\eta}}(s), \quad a_{\pi^{\eta}}(s, a) = q_{\pi^{\eta}}(s, a) - v_{\pi^{\eta}}(s)$$

$$a_{\pi^{\eta}}(s, a) = \mathbb{E}[R_t + \gamma v_{\pi^{\eta}}(S_{t+1}) - v_{\pi^{\eta}}(s) | S_t = s, A_t = a]$$

Advantage Actor-Critic (A2C): Основная идея

Аппроксимация Policy и Action-Value Function

$$\pi^\eta(a|s) \approx \pi_*(a|s), \quad V^\theta(s) \approx v_{\pi^\eta}(s)$$

Policy Gradient Theorem

$$\nabla_\eta J(\eta) = \mathbb{E}_{s \sim \rho_{\pi^\eta}, a \sim \pi^\eta} [\nabla_\eta \ln \pi^\eta(a|s) a_{\pi^\eta}(s, a)],$$

где

$$a_{\pi^\eta}(s, a) = \mathbb{E}[R_t + \gamma v_{\pi^\eta}(S_{t+1}) - v_{\pi^\eta}(s) | S_t = s, A_t = a]$$

Аппроксимация на шаге

Если $V^\theta \approx v_{\pi^\eta}$, то

$$\nabla_\eta J(\eta) \approx \nabla_\eta \ln \pi^\eta(A_t | S_t) (R_t + \gamma V^\theta(S_{t+1}) - V^\theta(S_t))$$

Advantage Actor-Critic (A2C): Основная идея

Аппроксимация Policy и Action-Value Function

$$\pi^\eta(a|s) \approx \pi_*(a|s), \quad V^\theta(s) \approx v_{\pi^\eta}(s)$$

Bellman Expectation Equation для v_π

$$v_{\pi^\eta}(s) = \mathbb{E}_{\pi^\eta}[R_t + \gamma v_{\pi^\eta}(S_{t+1}) | S_t = s]$$

Аппроксимация на шаге

Если

$$V^\theta(S_t) \approx R_t + \gamma V^\theta(S_{t+1}), \quad S_{t+1} \sim \mathcal{P}(\cdot | S_t, A_t), \quad A_t \sim \pi^\eta(\cdot | S_t)$$

то $V^\theta \approx v_{\pi^\eta}$

Advantage Actor-Critic (A2C)

Задаем структуру аппроксимаций $\pi^\eta(a|s)$, $V^\theta(s)$ и начальные вектора параметров η , θ .

Для каждого эпизода делаем:

Пока эпизод не закончен делаем:

- Находясь в состоянии S_t совершаем действие $A_t \sim \pi^\eta(\cdot|S_t)$, получаем награду R_t , переходим в состояние S_{t+1} .
- По (S_t, A_t, R_t, S_{t+1}) определяем Loss функции:

$$Loss_1(\theta) = (R_t + \gamma V^\theta(S_{t+1}) - V^\theta(S_t))^2$$

$$Loss_2(\eta) = \ln \pi^\eta(A_t|S_t) (R_t + \gamma V^\theta(S_{t+1}) - V^\theta(S_t))$$

и обновляем параметры:

$$\theta \leftarrow \theta - \alpha \nabla_\theta Loss_1(\theta), \quad \eta \leftarrow \eta + \beta \nabla_\eta Loss_2(\eta)$$

Организационные вопросы

- Пятница, 17:50, аудитория 622
- Отчетность: домашние работы
- Страничка курса: https://github.com/imm-rl-lab/UrFU_course
- E-mail для связи: a.r.plaksin@gmail.com

ВОПРОСЫ?